



大连理工大学 力学与航空航天学院

School of Mechanics and Aerospace Engineering, Dalian University of Technology

# 部分标注下基于物理和数据混合驱动的 结构温度场快速预测

杜洪泽, 阎军\*, 许琦

Email: [duhongze@mail.dlut.edu.cn](mailto:duhongze@mail.dlut.edu.cn)

# 目 录

1. 研究背景

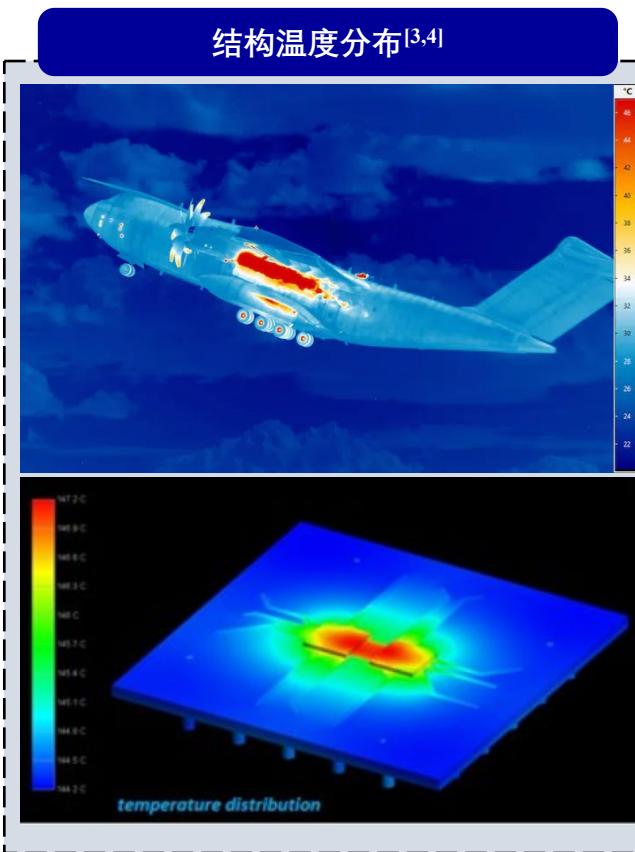
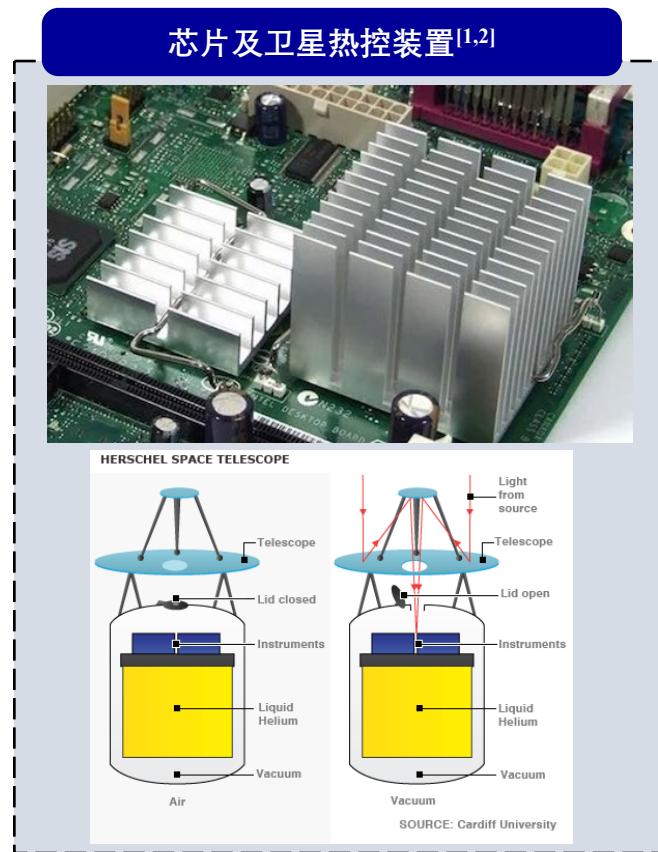
2. 研究内容

3. 结果与讨论

4. 结论与展望

# 1.1 研究背景

- 口 芯片制造、航空航天等领域中工业装备的集成化和多功能化发展，使得**结构的热管理**引起了广泛的关注
- 口 非均匀温度场引起的热应力和热应变会引起焊接疲劳和元件失效，**快速获得温度分布信息**可有效提高热管理效率
- 口 传统离散仅能获得**局部温度信息**，而利用**红外热像仪**等仪器存在**服役状态下能源供应和布设空间受限**等约束



发展基于有限温度测量数据的温度场快速重构或预测方法变得至关重要

[1] <https://www.rankred.com/best-examples-of-convection/>

[2] <https://www.herschel.caltech.edu/>

[3] <https://www.infratec.eu/thermography/industries-applications/aerospace-industry/>

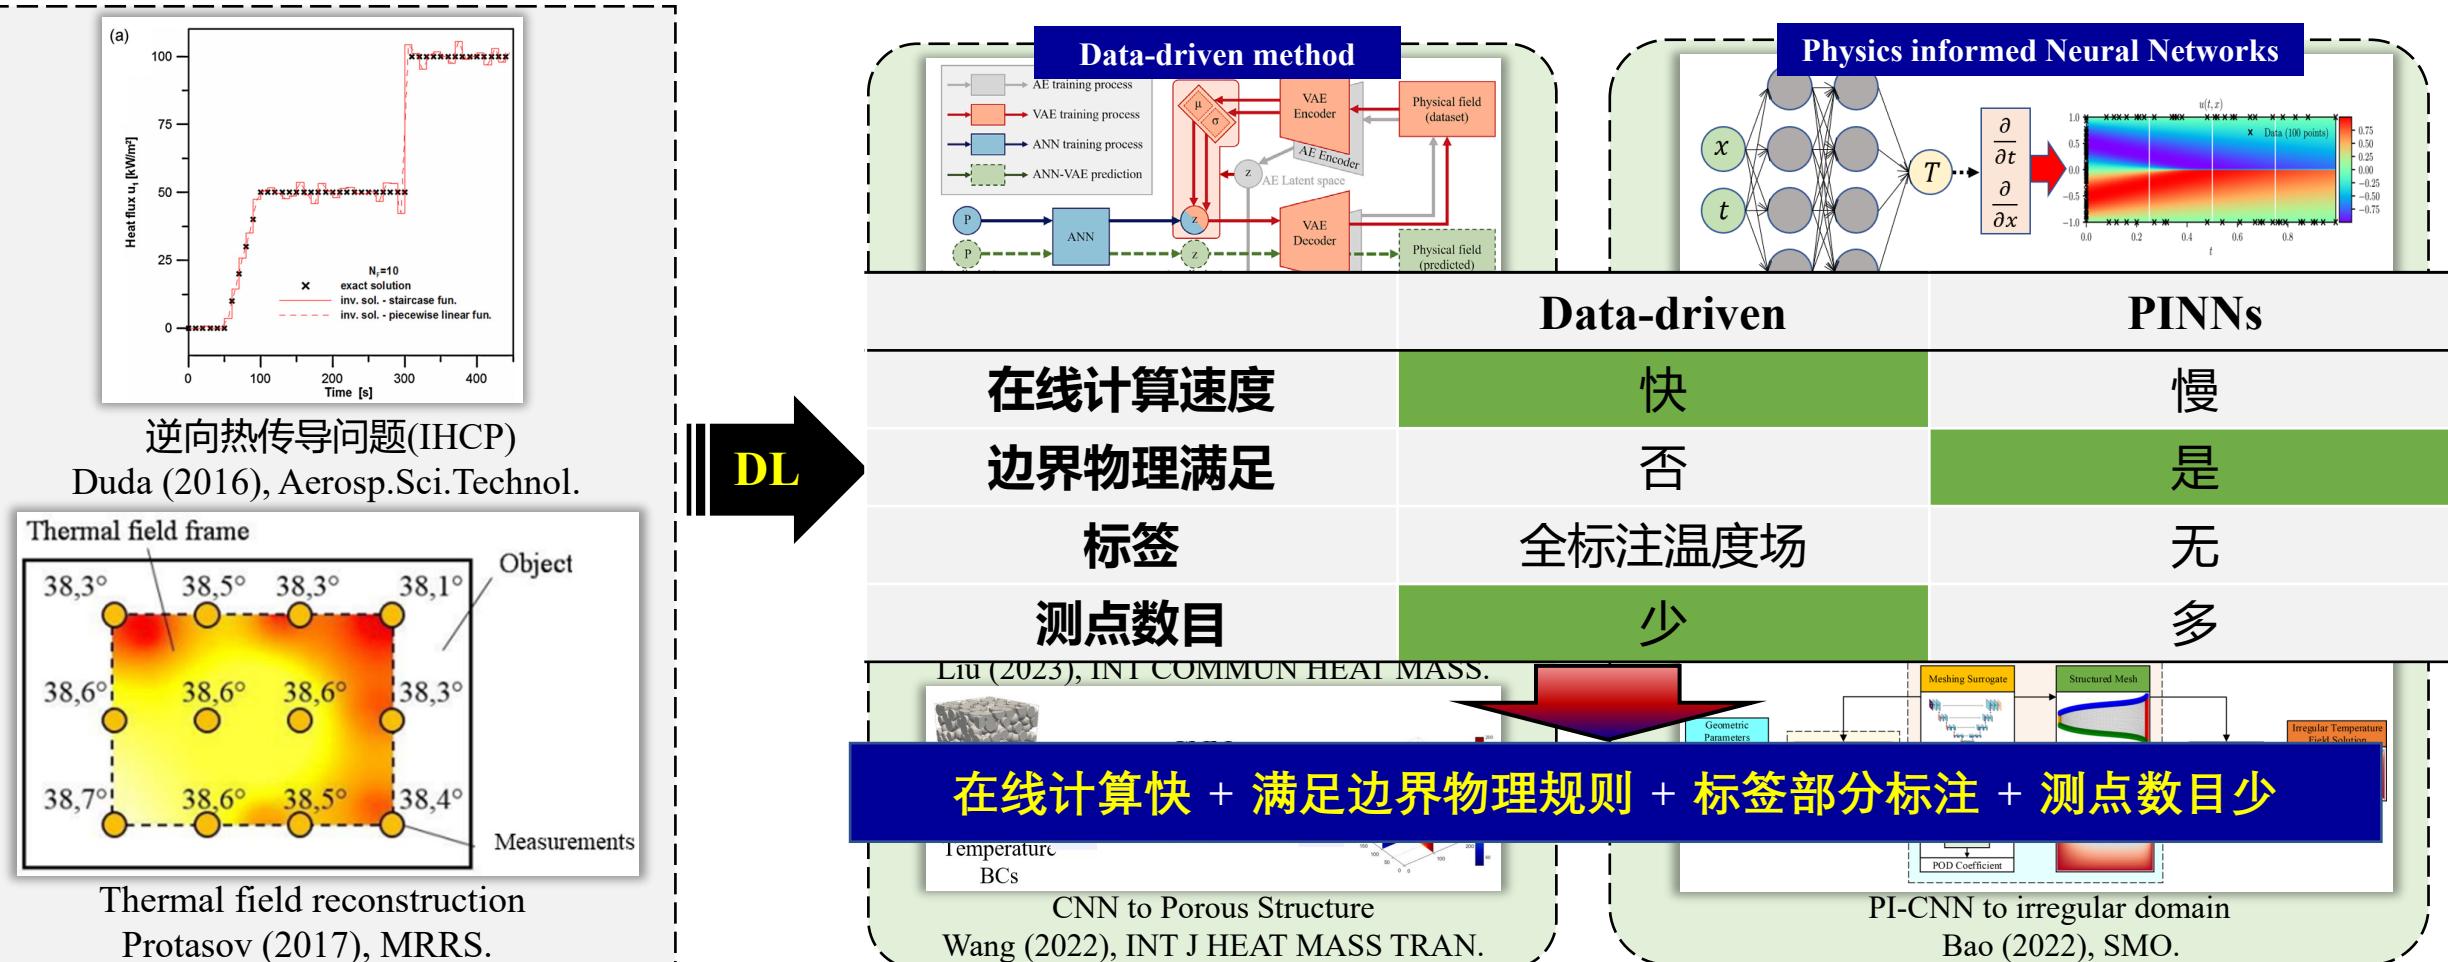
[4] <http://www.sitritec.com/case-5.html>

[3] <https://www.omegaengineering.cn/temperature/>

[4] <https://www.infiray.com/products/t400-t630-expert-level-thermal-camera.html>

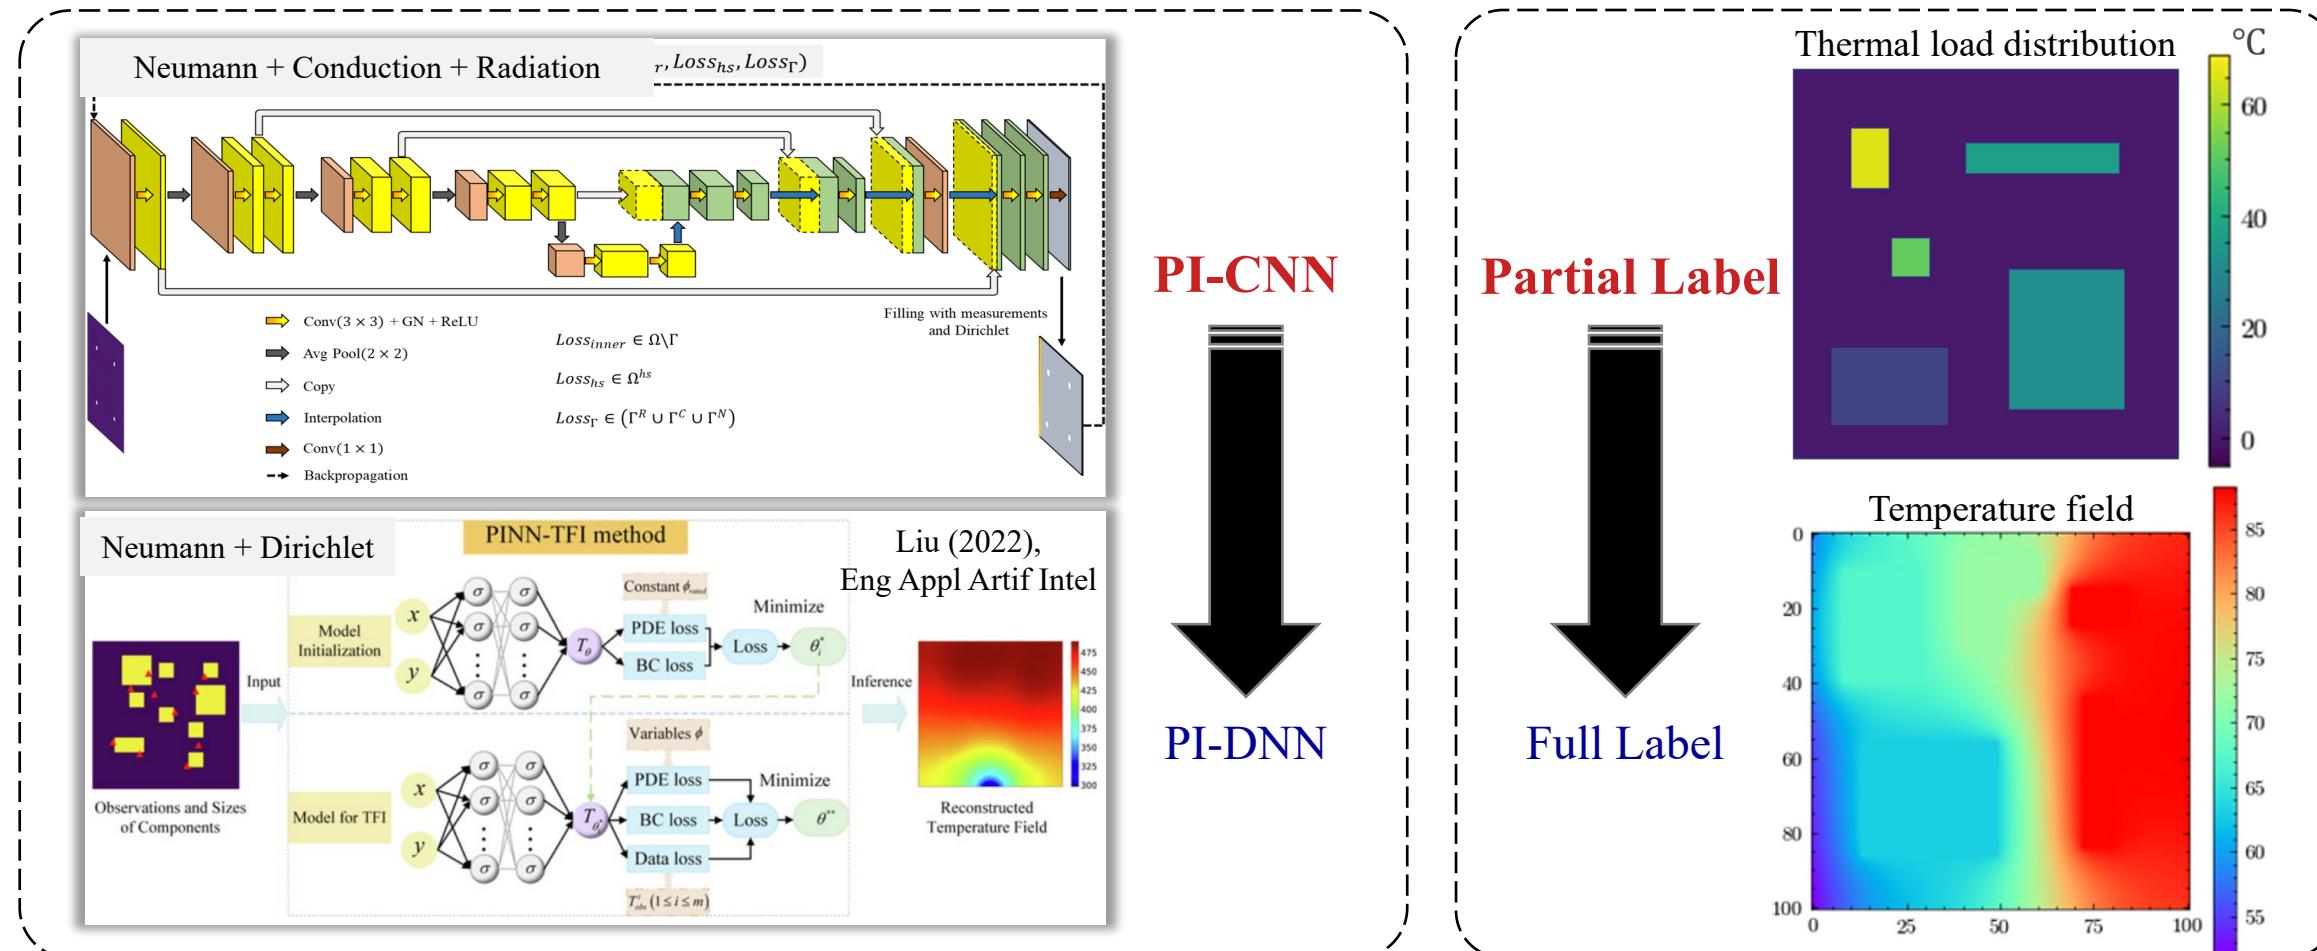
# 1.2 研究现状

- 基于热载荷逆向识别的间接温度场计算方法，通常需要耗时的迭代且存在识别误差扩大等问题
- 传统基于插值拟合的直接温度场重构方法，需要布置大量的传感器来获取足够的离散温度点数据
- 深度学习的强非线性计算能力为解决有限测量点到全场温度的复杂映射关系提供了新的途径



### 1.3 研究目标

- 提出一种基于物理和数据混合驱动的部分标注(**PLCoNet**)方法，实现有限测量下未知热载荷与结构温度场快速预测
  - 构建一个统一的深度学习模型，利用数据驱动模块**逆向识别热载荷**，物理引导模块进行**正向温度场计算**
  - 针对难以避免的测量误差，通过高斯白噪声模拟来验证**PLCoNet**方法的鲁棒性



PLCoNet仅需要部分标注数据作为输出标签，具有快速计算能力，且对测量误差具有高鲁棒性

# 目 录

1. 研究背景

2. 研究内容

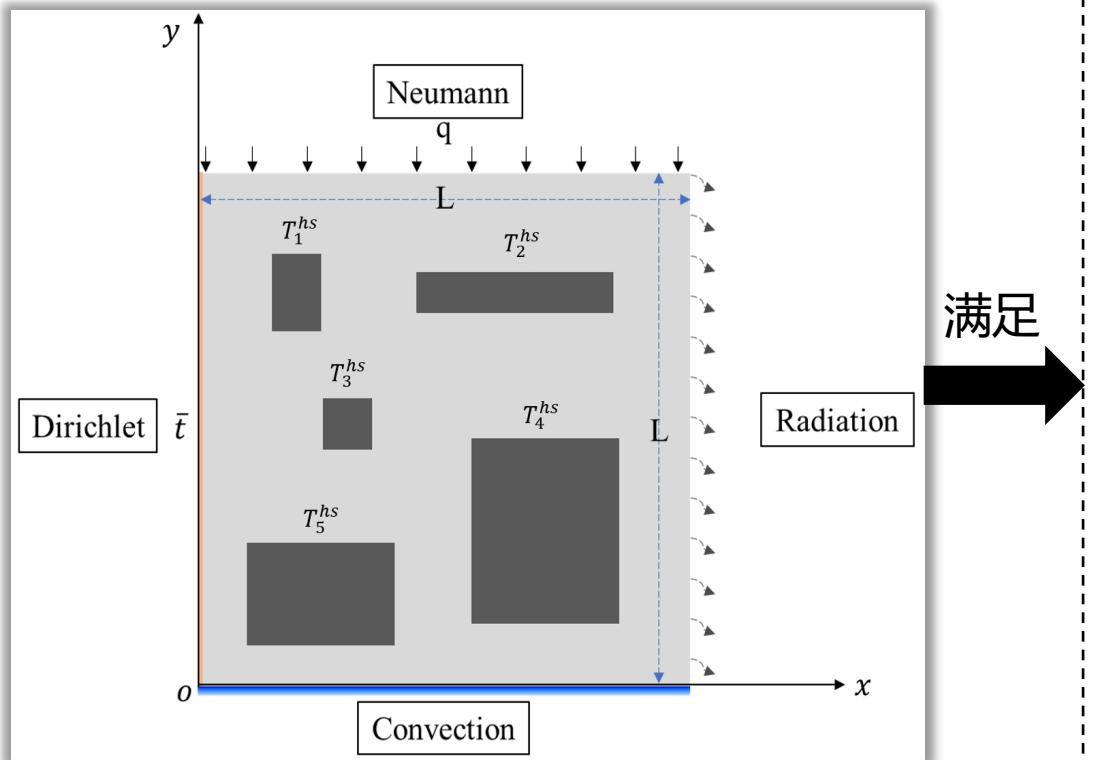
3. 结果与讨论

4. 结论与展望

## 2.1 问题建模

□ 面向具有复杂热力学边界 $\Gamma$ 和 $m$ 个内部热源 $Q(x, y)$ 的结构, 给定 $n$ 个传感器的温度数据 $\tilde{t} \in \mathbb{R}^n$

- 基于温度测点数据来对结构的内部载荷分布进行逆向识别,  $Q = f^{inv}(\tilde{t})$
- 利用获得的内部热载荷和边界条件实现正向的结构温度场计算,  $T = f^{for}(Q, BC)$



■ 求解域:  $\Omega = (0, L) \times (0, L)$

■ 热载荷:  $Q(x, y) = \begin{cases} T_m^{hs}, & (x, y) \in \Omega_m^{hs} \quad m \in 1, \dots, m \\ 0, & others \end{cases}$

■ 物理规则: 泊松方程 + 边界条件

$$\lambda \frac{\partial^2 T}{\partial x^2} + \lambda \frac{\partial^2 T}{\partial y^2} + Q(x, y) = 0, (x, y) \in \Omega$$

$$T(x, y) = \bar{t}, (x, y) \in \Gamma^D$$

$$-\lambda \frac{\partial T}{\partial n} = \varepsilon \mu ((T - t_K)^4 - (t_a - t_K)^4), (x, y) \in \Gamma^R$$

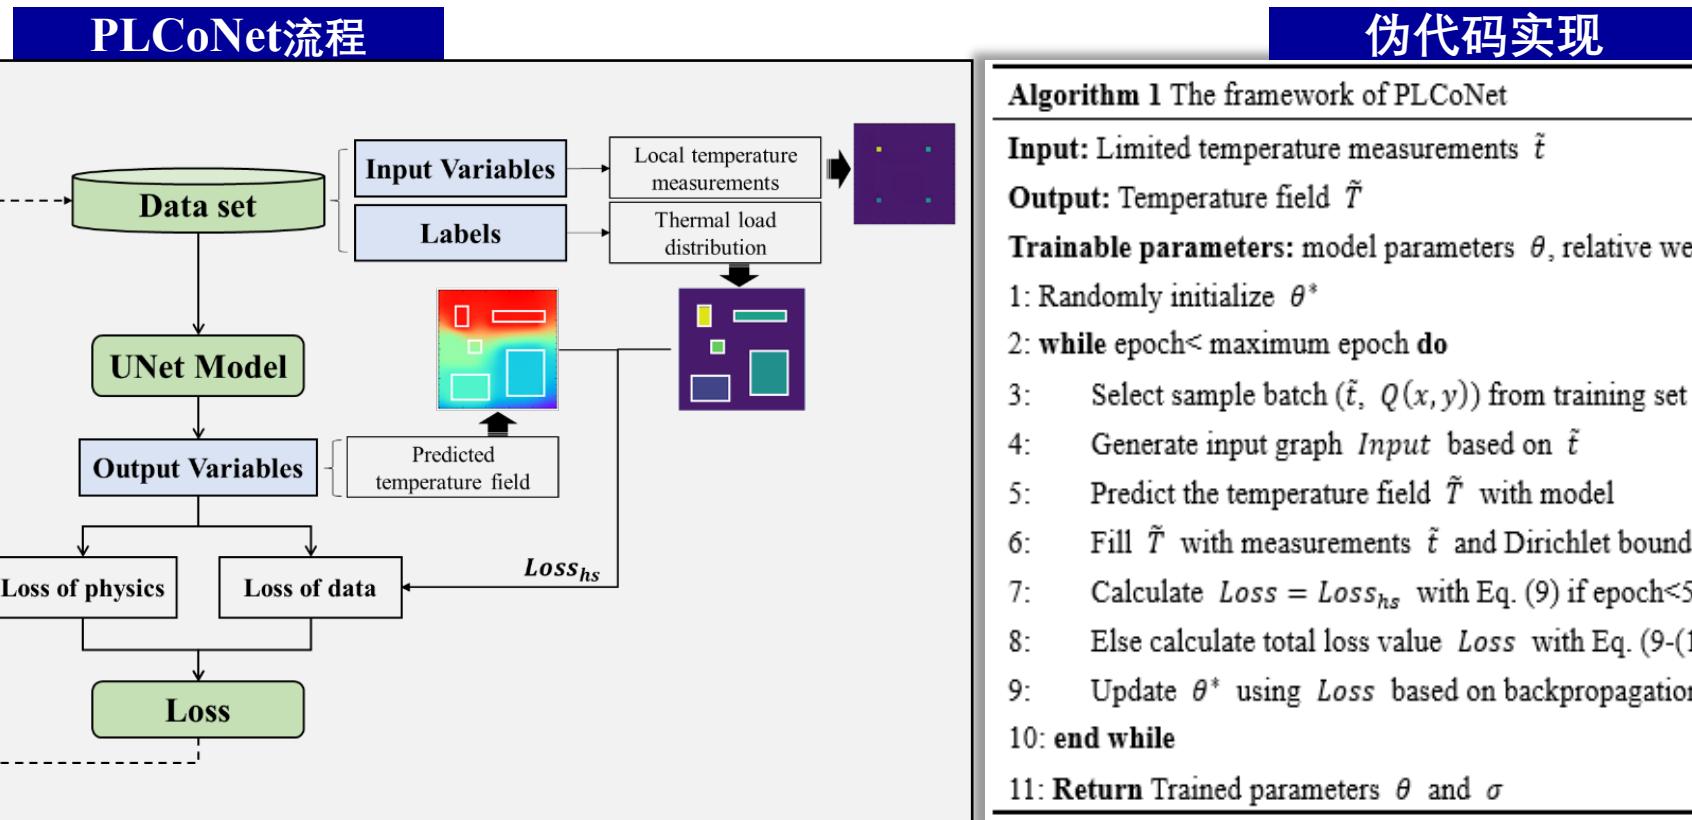
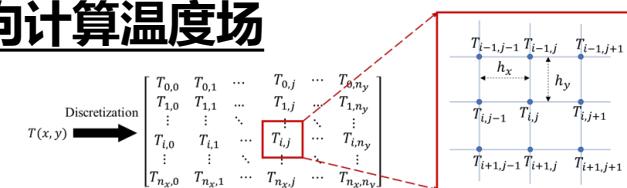
$$-\lambda \frac{\partial T}{\partial n} = h(T - t_a), (x, y) \in \Gamma^C$$

$$-\lambda \frac{\partial T}{\partial n} = q, (x, y) \in \Gamma^N$$

## 2.2 研究内容

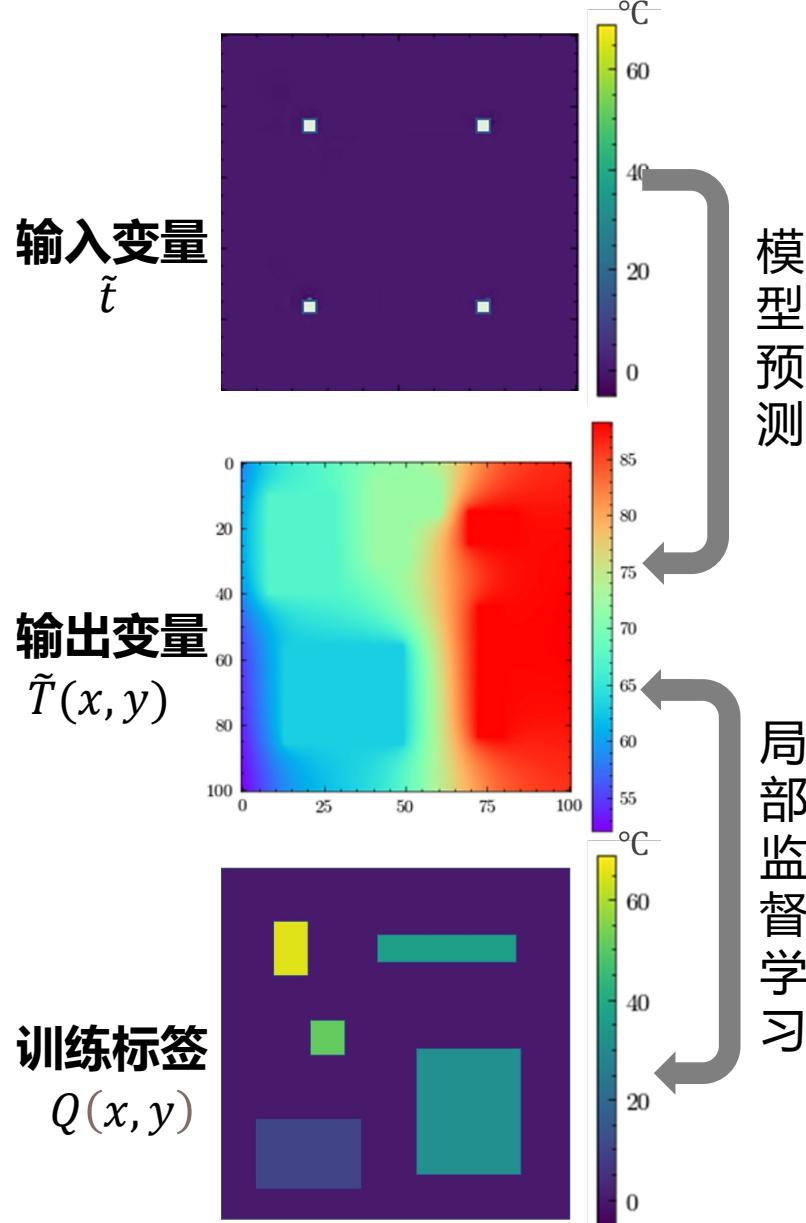
核心思想：数据驱动基于离散测量温度逆向识别热载荷，物理驱动基于热力学规则正向计算温度场

1. 结构网格划分，将连续的函数分布离散化表示为  $(Q_{i,j}, T_{i,j})$
2. 利用有限差分方法(FDM)将泊松方程和边界条件转化为节点温度间的相互约束关系，嵌入至损失函数
3. 基于UNet模型进行结构温度场预测，计算损失函数后进行误差反向传播训练，直至模型收敛

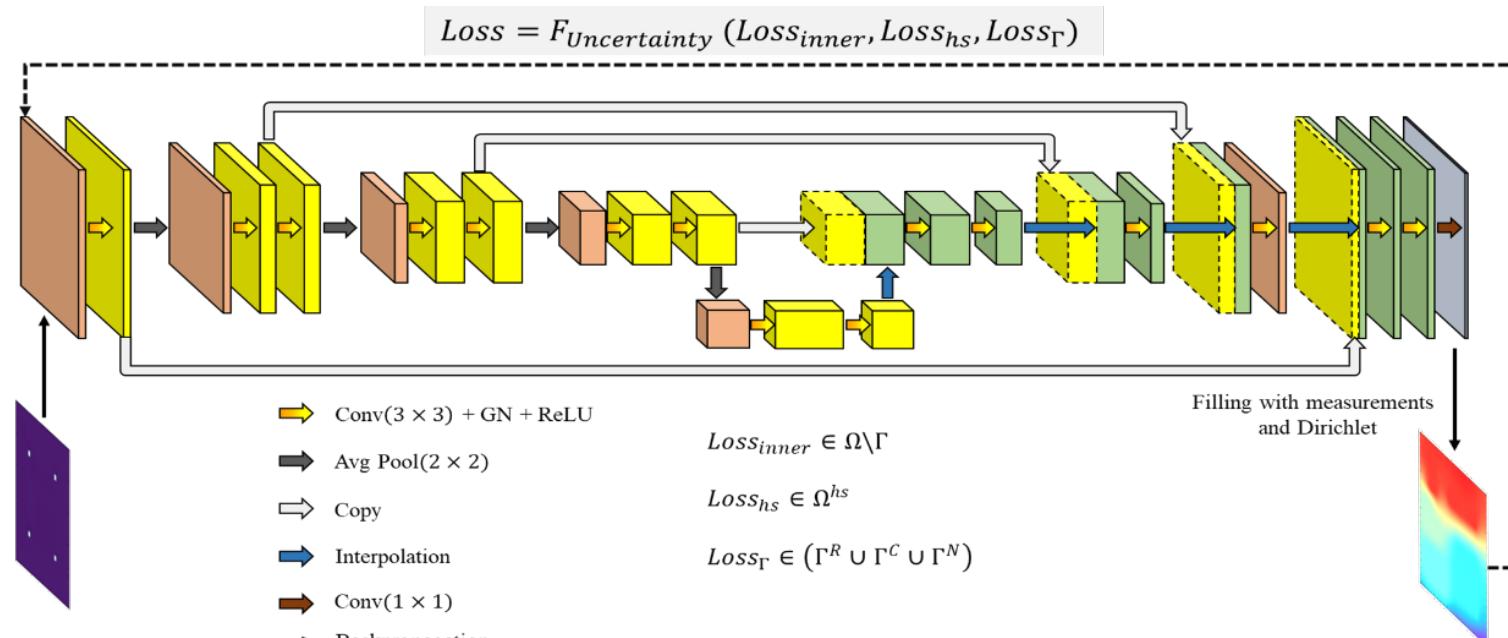


## 2.3 数据准备及模型搭建

### □ 数据准备：输入变量+输出变量+训练标签



### □ 模型搭建：UNet



- 该模型包括两个部分：数据编码降维和特征解码输出  
黄色箭头表示 $3 \times 3$ 卷积层，GroupNorm层和ReLU激活函数
- 黑色箭头表示 $2 \times 2$ 平均池化层
- 白色箭头表示残差连接
- 蓝色箭头表示 $2 \times 2$ 上采样块和bilinear拟合
- 红色箭头表示 $1 \times 1$ 全卷积计算

详细的模型细节可参考文献，Bao(2022), SMO

## 2.4 损失函数定义

口 基于不确定性的损失函数:

$$Loss = \sum_k \delta \left( \frac{1}{2\sigma_k^2} Loss_j + \log \sigma_k^2 \right) \quad \text{状态因子} \delta = \begin{cases} 1, \text{True} \\ 0, \text{False} \end{cases}$$

➤ 数据驱动损失:  $Loss_{hs} = \sum_{\Omega^{hs}} \left| T_{i,j}^{hs} - \widetilde{T}_{i,j}^{hs} \right| \quad (i,j) \in \Omega^{hs}$   计算热载荷作用区域

➤ 物理驱动损失: 泊松方程 + 边界条件

域内损失  $Loss_{inner} = \sum_{\Omega} |e_{i,j}^{inner}| \quad \leftarrow e_{i,j}^{inner} = h_y^2(T_{i+1,j} + T_{i-1,j}) + h_x^2(T_{i,j+1} + T_{i,j-1}) - 2(h_x^2 + h_y^2)T_{i,j}$

Radiation  $Loss_{\Gamma^R} = \sum_{\Gamma^R} (|e_{n_x,j}^{\Gamma^R}|) \quad \leftarrow e_{n_x,j}^{\Gamma^R} = 2T_{n_x-1,j} - \left( 2 + \frac{2}{r^2} \right) T_{n_x,j} + \frac{1}{r^2} (T_{n_x,j+1} + T_{n_x,j-1}) - \frac{2h_x \varepsilon \sigma}{\lambda} \left( (T_{n_x,j} - t_K)^4 - (t_a - t_K)^4 \right)$

Neumann  $Loss_{\Gamma^N} = \sum_{\Gamma^N} (|e_{i,n_y}^{\Gamma^N}|) \quad \leftarrow e_{i,n_y}^{\Gamma^N} = (2 + 2r^2)T_{i,n_y} - 2T_{i,n_y-1} - r^2 (T_{i+1,n_y} + T_{i-1,n_y}) - 2 \frac{h_y q}{\lambda}$

Conduction  $Loss_{\Gamma^C} = \sum_{\Gamma^C} (|e_{n_x,j}^{\Gamma^C}| + |TGR_{n_x,j}|) \quad \leftarrow e_{n_x,j}^{\Gamma^C} = \left( \frac{2}{r^2} + 2 + C_x \right) T_{n_x,j} - \frac{1}{r^2} (T_{n_x,j+1} + T_{n_x,j-1}) - 2T_{n_x-1,j} - C_x t_a$

温度梯度正则化项  $TGR_{n_x,j} = A e^{B(T_{i,n_x} - T_{i,n_x-1})}$  A 和 B 分别为缩放因子和惩罚因子

$h_y$  和  $h_x$  分别为 x 方向和 y 方向网格尺寸,  $n_x$  和  $n_y$  分别为 x 方向和 y 方向节点数目,  $R = \frac{h_y}{h_x}$ ,  $C_y = \frac{2h_y h}{\lambda}$

# 目 录

1. 研究背景

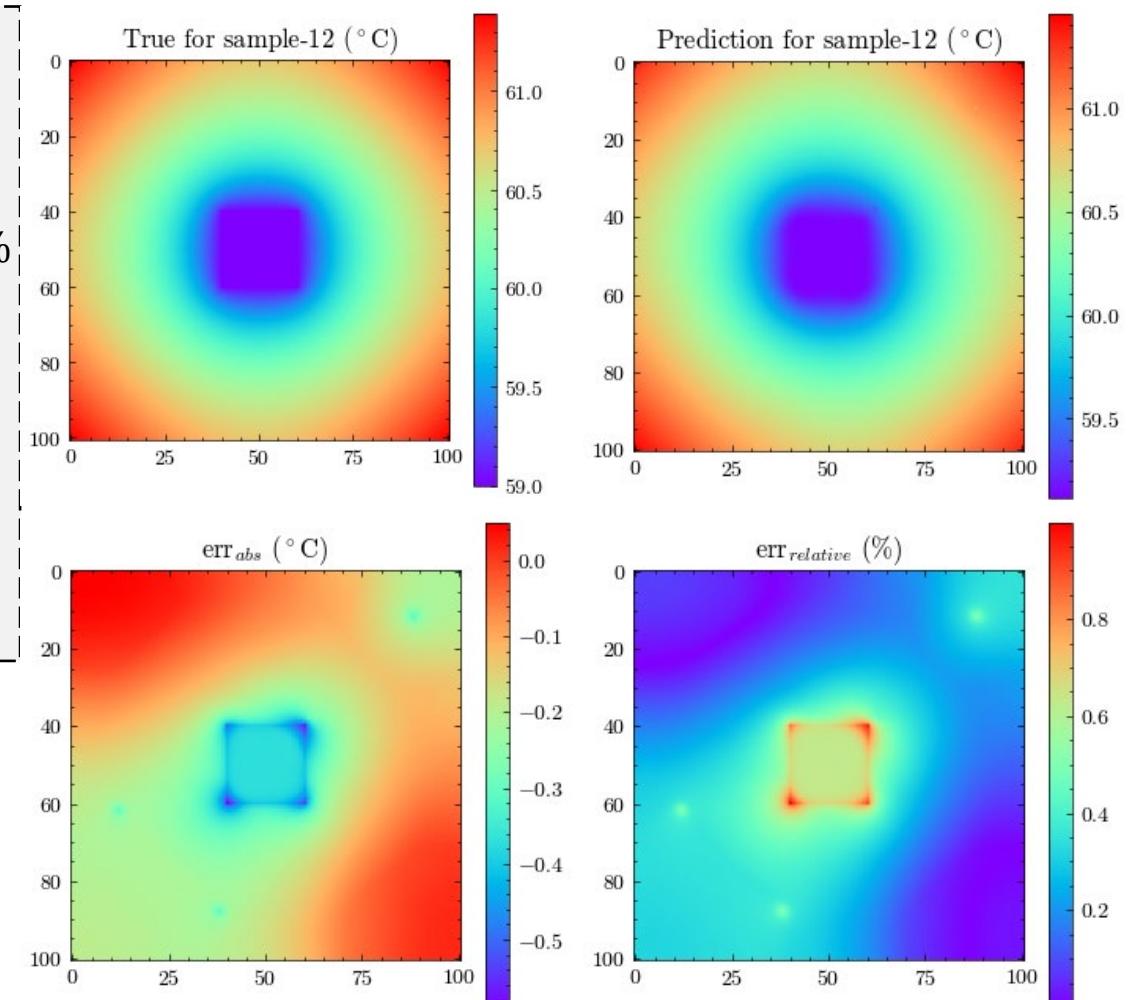
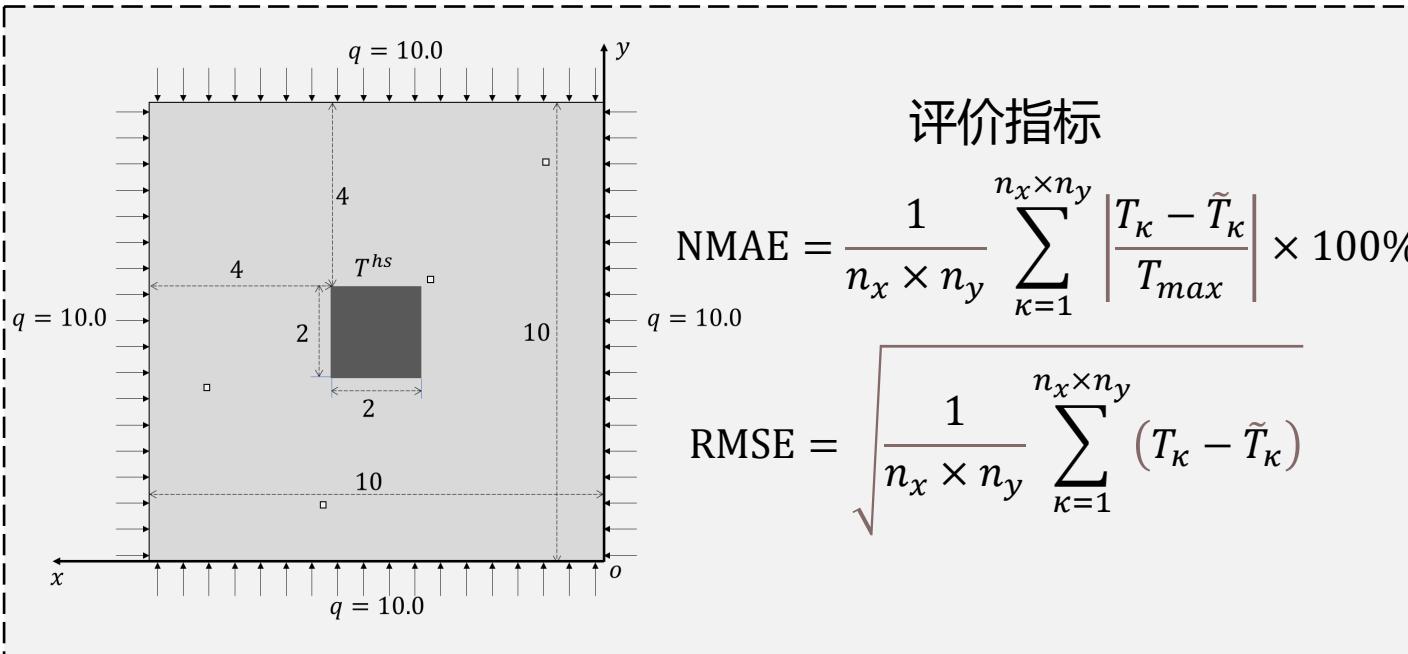
2. 研究内容

3. 结果与讨论

4. 结论与展望

# 3.1 模型性能评估

## □ Case-1: 具有一个内热源和Neumann边界

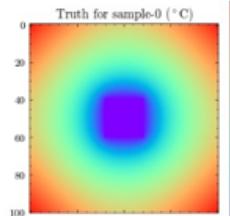
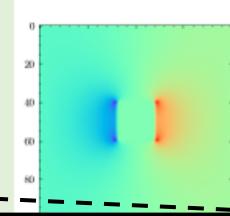
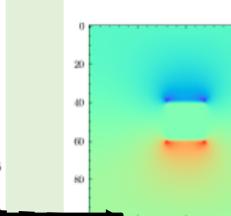
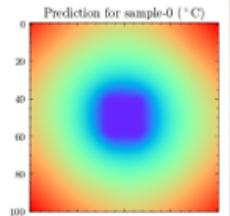
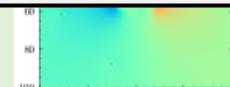
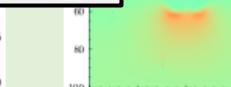
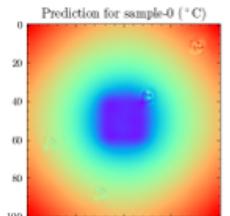
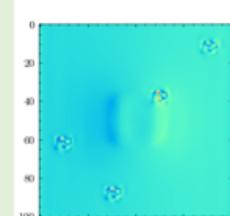
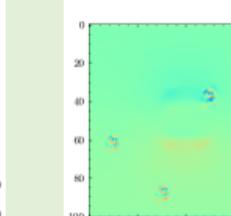
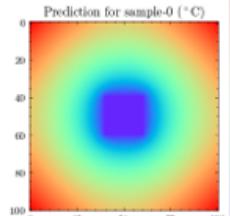
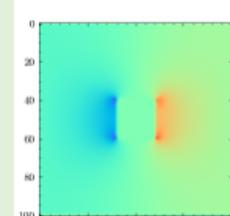
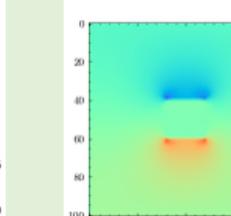


测试集误差				
NMAE	RMSE	$Loss_{hs}$	$Loss_{inner}$	$Loss_{\Gamma}$
error	0.11%	0.08°C	0.08°C	$1.06 \times 10^{-5}$ $1.43 \times 10^{-4}$

- 单个样本的预测结果, 绝对误差均小于0.3°C, **最大相对误差不超过0.5%**
- 整个测试集的预测结果, 很好地满足物理规则, 且平均的**NMAE**和**RMSE**分别为**0.11%**和**0.08°C**

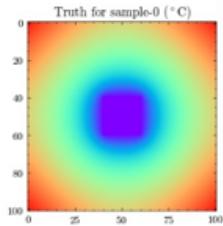
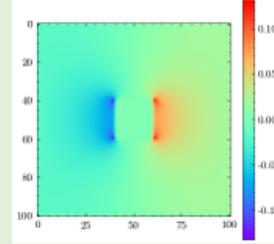
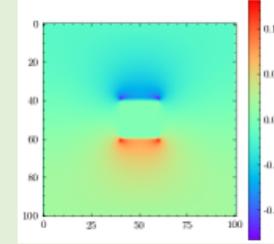
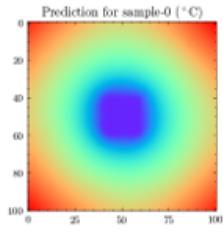
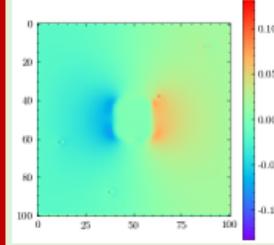
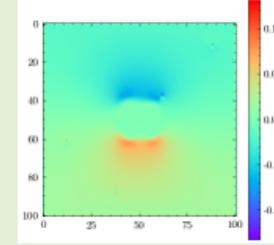
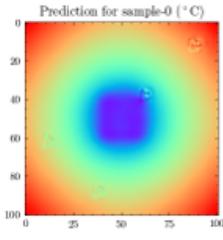
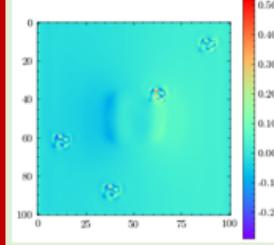
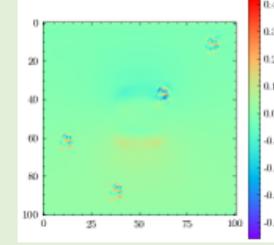
## 3.2 与数据驱动和PINNs的对比

PLCoNet  Co-driven

	Temperature field	On-line time	NMAE	RMSE	$loss_{hs}$	$loss_{inner}$	$loss_{\Gamma}$	$TG_x$	$TG_y$
Truth		-	-	-	0	$8.85 \times 10^{-6}$	$8.05 \times 10^{-6}$		
PLCoNet		0.05 s	0.03%	0.03°C	$1.42 \times 10^{-4}$	$3.08 \times 10^{-4}$			
Data-driven		0.01 s	0.03%	0.03°C	$0.03 \times 10^{-4}$	$0.03 \times 10^{-4}$			
PINNs		47m13s	0.33%	0.03°C	$0.12 \times 10^{-4}$	$8.19 \times 10^{-6}$	$5.26 \times 10^{-4}$		

需要注意的是参考温度场  $T$  的内部和边界处的物理损失不为零的原因在于，利用FEM和FDM计算温度场时的固有数值误差

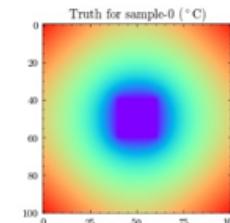
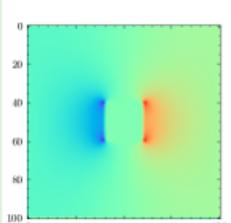
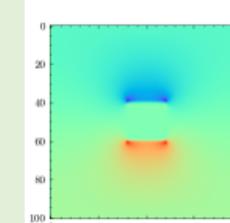
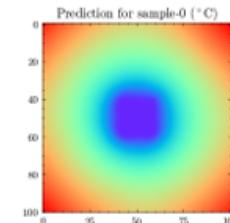
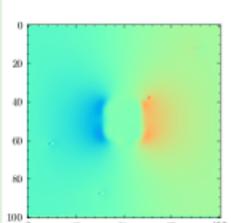
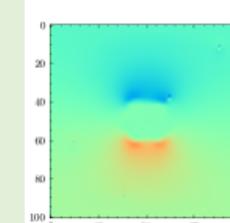
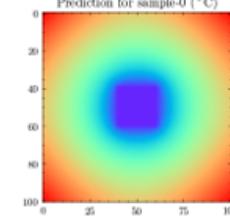
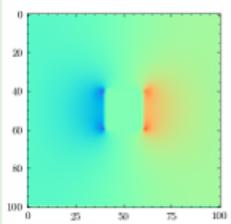
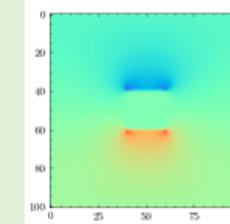
## 3.2 与数据驱动和PINNs的对比

	Temperature field	On-line time	NMAE	RMSE	$loss_{hs}$	$loss_{inner}$	$loss_{\Gamma}$	$TG_x$	$TG_y$
Truth		-	-	-	0	$8.85 \times 10^{-6}$	$8.05 \times 10^{-6}$		
PLCoNet		0.05 s	0.07%	0.06°C	0.13°C	$1.20 \times 10^{-5}$	$1.57 \times 10^{-4}$		
Data-driven		0.01 s	0.03%	0.03°C	0.03°C	$1.42 \times 10^{-4}$	$3.08 \times 10^{-2}$		

- 与数据驱动的对比:
  - 1) 计算时间均不到0.1s, 具有较高的计算效率
  - 2) 数据驱动不能很好地满足物理规则, 其物理损失大了两个数量级
  - 3) PLCoNet的预测结果较为符合真实的物理梯度场分布

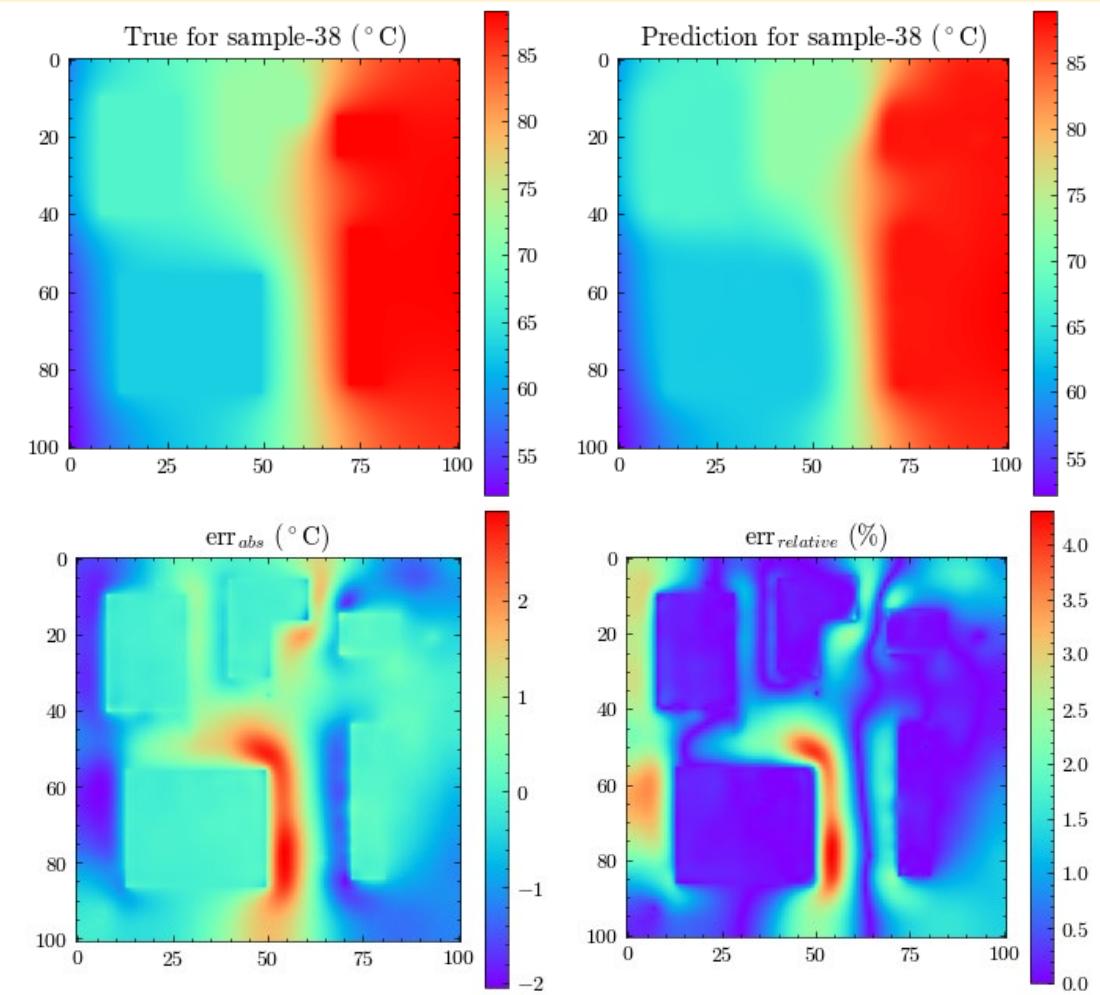
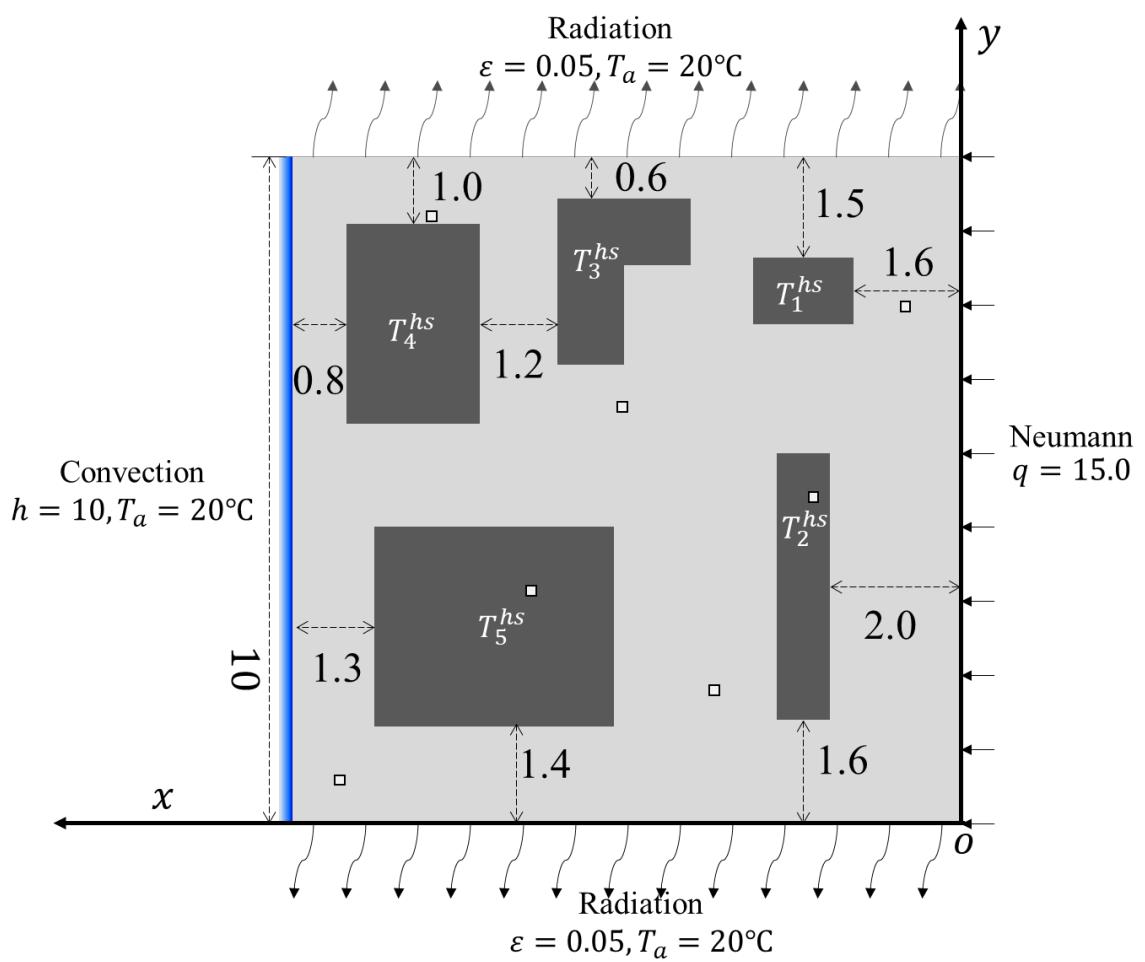
## 3.2 与数据驱动和PINNs的对比

PLCoNet  Co-driven

	Temperature field	On-line time	NMAE	RMSE	$loss_{hs}$	$loss_{inner}$	$loss_{\Gamma}$	$TG_x$	$TG_y$
Truth		-	-	-	0	$8.85 \times 10^{-6}$	$8.05 \times 10^{-6}$		
PLCoNet		0.05 s	0.07%	0.06°C	0.13°C	$1.20 \times 10^{-5}$	$1.57 \times 10^{-4}$		
PINNs		47m13s	0.33%	0.03°C	0.12°C	$8.19 \times 10^{-6}$	$5.26 \times 10^{-4}$		

- 与PINNs的对比: 1) 均可以很好地满足物理规则  
2) PLCoNet具有更快的计算速度

### 3.3 Case-2: 具有多个内热源和复杂边界

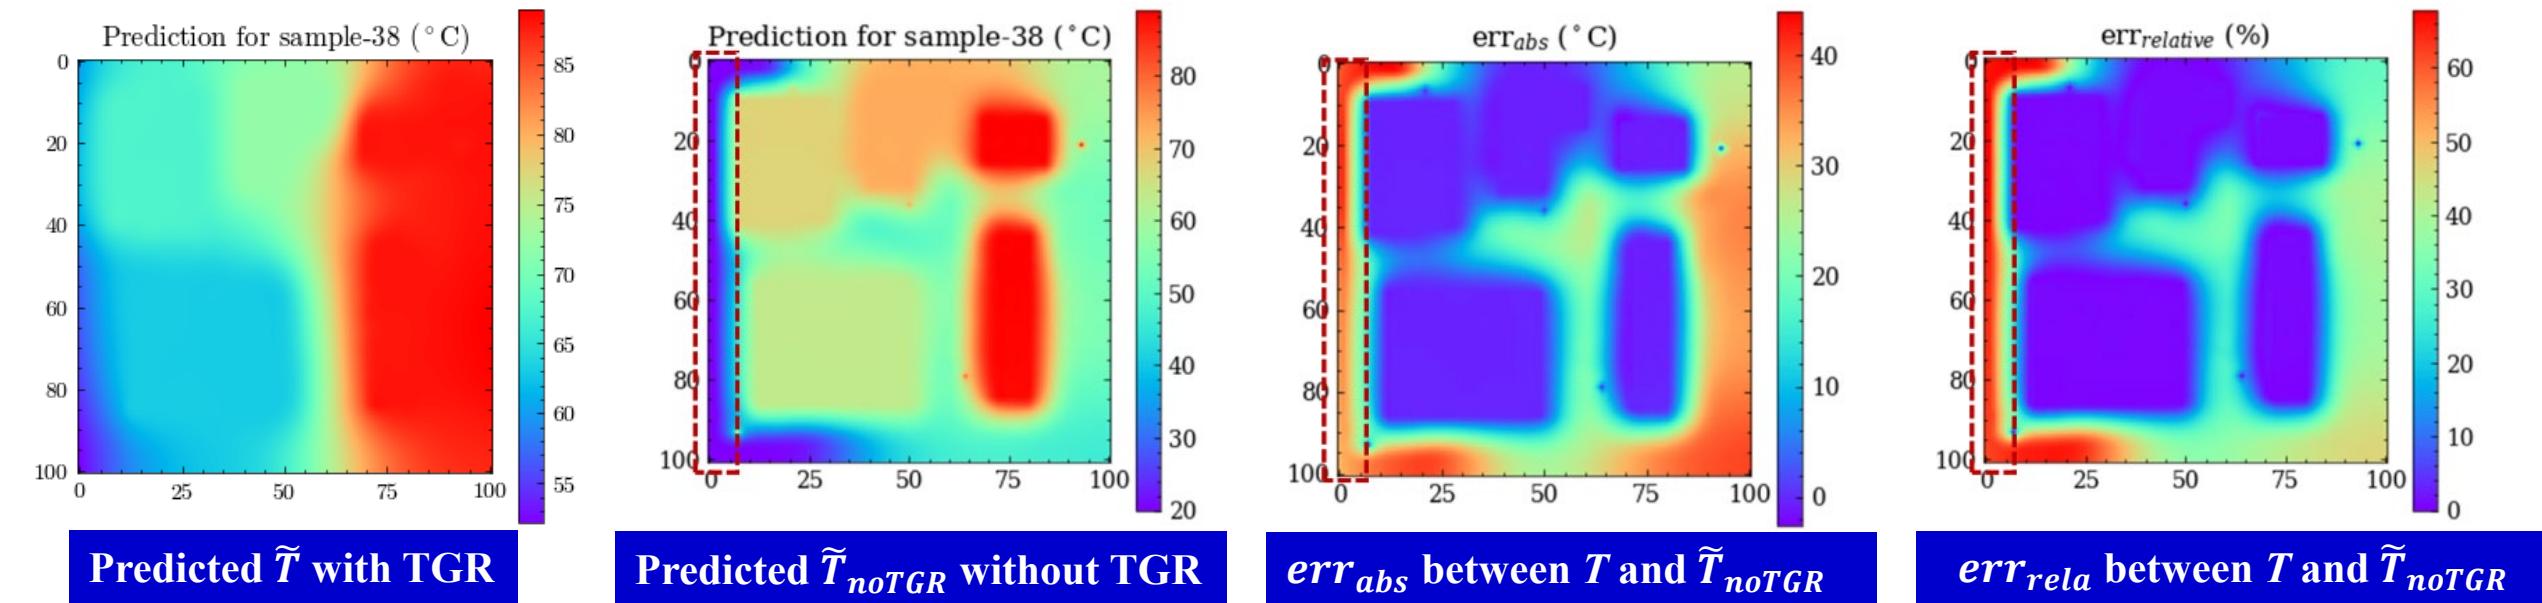


	<b>NMAE</b>	<b>RMSE</b>	<b>Loss<sub>hs</sub></b>	<b>Loss<sub>inner</sub></b>	<b>Loss<sub><math>\Gamma^C</math></sub></b>	<b>Loss<sub><math>\Gamma^R</math></sub></b>	<b>Loss<sub><math>\Gamma^N</math></sub></b>
<b>Truth</b>	-	-	0°C	$7.10 \times 10^{-4}$	$4.92 \times 10^{-3}$	$3.79 \times 10^{-4}$	$4.64 \times 10^{-5}$
<b>Prediction</b>	1.57%	2.09°C	0.15°C	$7.89 \times 10^{-4}$	$5.58 \times 10^{-3}$	$8.57 \times 10^{-4}$	$5.22 \times 10^{-4}$

PLCoNet方法可以精确捕捉到结构温度场的复杂热力学变化，平均误差仅为1.57%

## 3.4 温度梯度正则化的影响

通过对比 $Loss_{\Gamma^C}$ 有无温度梯度正则化项来说明TGR的作用



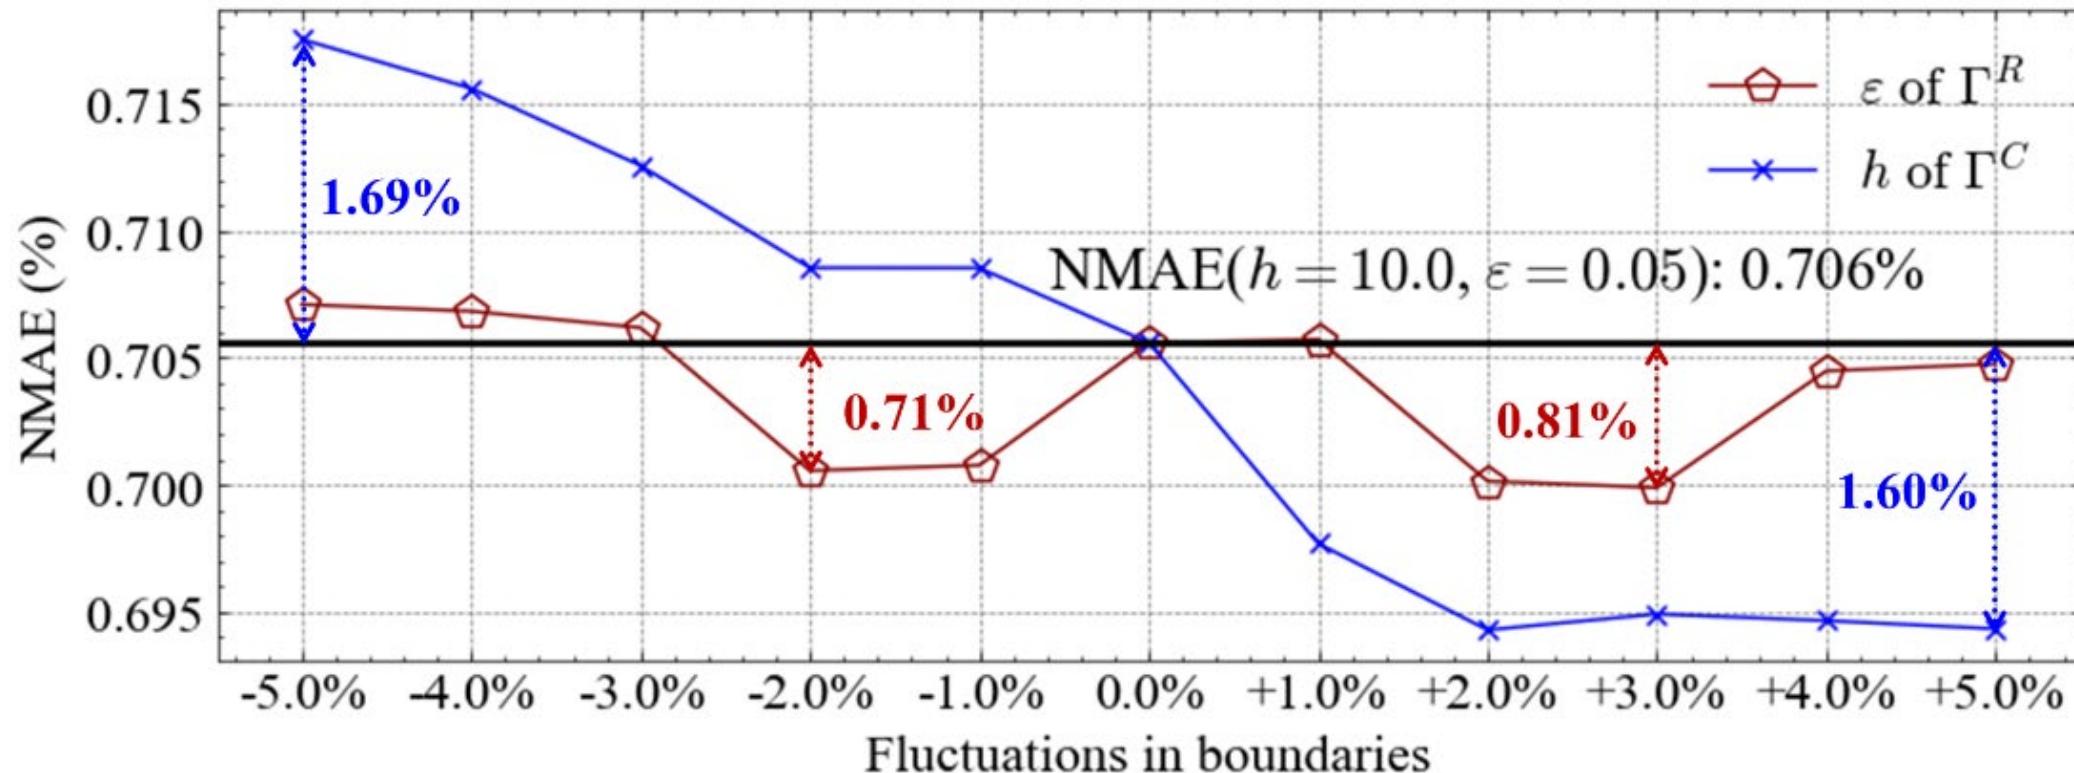
	$Loss_{hs}$	$Loss_{inner}$	$Loss_{\Gamma^C}$	$Loss_{\Gamma^R}$	$Loss_{\Gamma^N}$
without TGR	0.51 $^{\circ}\text{C}$	$4.38 \times 10^{-3}$	$3.52 \times 10^{-5}$	$1.11 \times 10^{-3}$	$3.04 \times 10^{-4}$
PLCoNet	0.08 $^{\circ}\text{C}$	$4.54 \times 10^{-4}$	$2.41 \times 10^{-3}$	$6.91 \times 10^{-4}$	$5.30 \times 10^{-4}$

对比PLCoNet方法，无TGR的损失值变化不大，甚至其 $Loss_{\Gamma^C}$ 小两个数量级，但预测精度远不如PLCoNet方法

引入TGR可以有效使模型跳出错误的局部最优解，避免出现环境温度值在热对流边界蔓延的现象

### 3.5 Impact of boundary parameter uncertainties

- 环境波动会引起热对流边界( $\Gamma^C$ )的对流换热系数  $h$  和热辐射边界( $\Gamma^R$ )的材料表面发射率  $\varepsilon$  产生不确定性



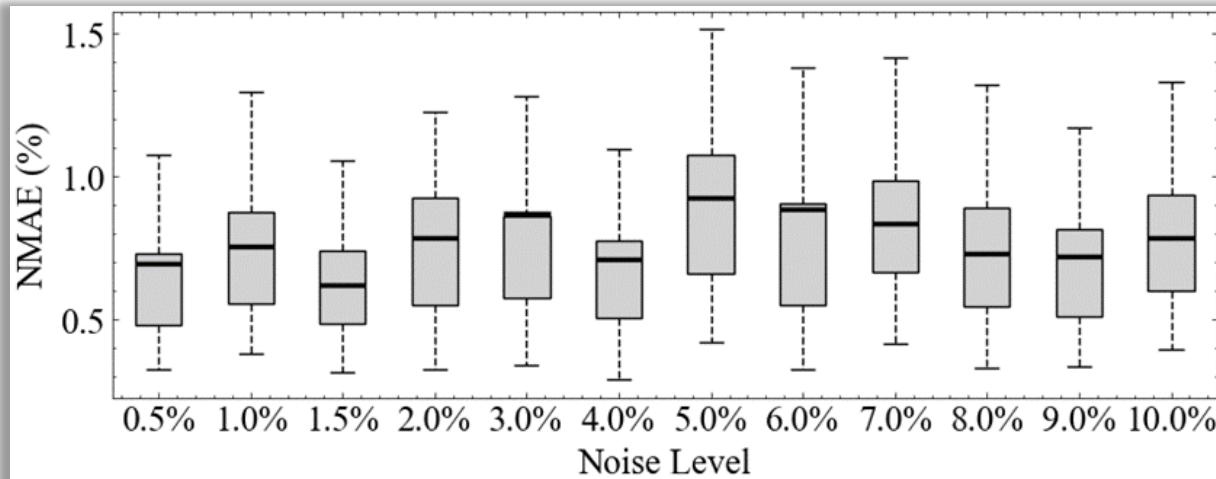
- 当热对流换热系数降低5%，预测误差NMAE最大增加1.69%
- 材料表面发射率对于预测结果的影响较小

PLCoNet对于边界热力学参数的不确定性具有较强的

## 3.6 模型鲁棒性讨论

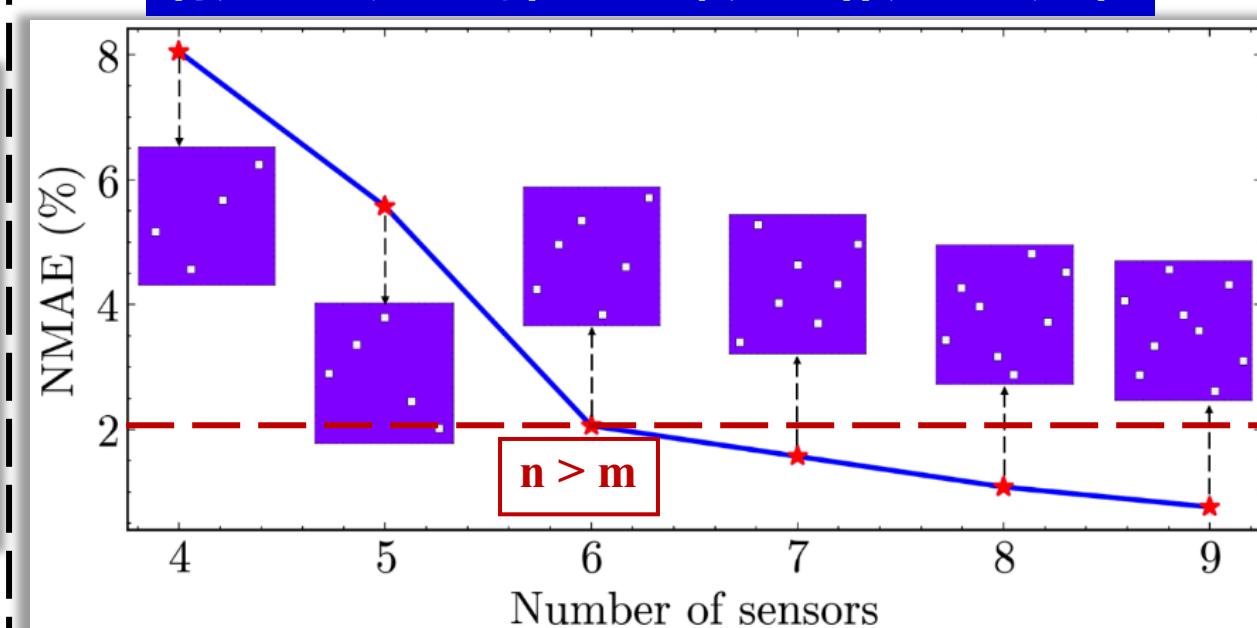
### 口 噪声鲁棒性分析:

在数据集中加入0.5%至10.0%的高斯白噪声



### 口 传感器布局方案影响分析:

利用LHS随机选择4至9个传感器作为布局方案



➤ PLCoNet方法测试集上的平均误差均处于0.5%至1.0%之间，最大预测误差小于1.6%

➤ PLCoNet方法测试集上误差随着传感器数量的增加而降低，但最大的平均误差也约为8%  
 ➤ 传感器数量大于内部热载荷数量( $n > m$ )，误差均小于2%

PLCoNet方法对于传感器测量误差表现出强大的鲁棒性  
 通过有限度的增加传感器数量，可以显著提高模型的温度场预测精度

# 目 录

1. 研究背景

2. 研究内容

3. 结果与讨论

4. 结论与展望

## 5 结论与展望

口 **结论：**提出了一种新型的**部分标注下的物理和数据混合驱动方法PLCoNet**，可以在有限测量数据下实现对温度场进行快速预测。并且该方法融合了数据驱动和PINNs的优点，利用一个神经网络同时识别未知热载荷和重构结构温度场

1. PLCoNet可以**仅将热载荷分布作为标签**进行监督学习，可以显著降低深度学习方法在温度场预测中的应用成本。在简单的Case-1上进行温度场预测时，其平均预测误差仅有0.11%，在线计算时间仅为0.05s；
2. 通过将传热学中的热对流边界和热辐射边界引入至PLCoNet，该方法可以对**具有多个内部热源和多种边界条件下的复杂结构**(Case-2)进行快速的温度场预测，并且其平均预测误差为1.57%；
3. 利用高斯白噪声模拟温度测量误差，验证了PLCoNet方法的鲁棒性。在通过引入不同水平的误差时，**预测误差并不会随着噪声的增加而增大**。并且在加入10%的噪声时，模型在测试集上的平均预测误差小于1.5%。

口 **展望：**1). 高温度梯度区域修正；2). 扩展至3D具有复杂几何形状的结构；3). 搭建实验平台，基于真实数据进行研究

謝謝